



## Plans à probabilités inégales

**Exercice 1:** Une population est composée de 6 ménages de tailles respectives 2; 4; 3; 9; 1 et 2 (la taille  $x_k$  d'un ménage  $k$  est le nombre de personnes physiques qu'il comprend). On tire 3 ménages sans remise, avec une probabilité proportionnelle à leur taille.

1. On a pour tout  $k$  :  $\pi_k = n \frac{x_k}{t_x}$  avec  $n = 3$  et  $t_x = 2 + 4 + 3 + 9 + 1 + 2 = 21$  donc

$$\pi_k = \frac{x_k}{7}, \quad k \in U$$

pour  $k = 4$  on voit bien que  $\pi_4 = \frac{9}{7} > 1$  alors on assigne la valeur 1 à  $\pi_4$  ( $\pi_4 = 1$ )

et

$$\pi_k = (n - 1) \frac{x_k}{t_x - 9} \quad \text{pour } k = 1; 2; 3; 5; 6$$

donc on recalcule les  $\pi_k$  pour les autres unités, selon :

$$\pi_k = 2 \frac{x_k}{12} = \frac{x_k}{6}$$

Finalement, les probabilités d'inclusion sont présentées dans le tableau suivant

$k$	1	2	3	4	5	6
$\pi_k$	$\frac{1}{3}$	$\frac{2}{3}$	$\frac{1}{2}$	1	$\frac{1}{6}$	$\frac{1}{3}$

On peut vérifier que  $\sum_k \pi_k = 3$ .

2. On tire un réel aléatoire  $u$  entre 0 et 1, et on s'intéresse aux probabilités cumulées présentées dans le tableaux suivant

$k$	1	2	3	4	5	6
$c_k = \sum_{j=1}^k \pi_j$	$\frac{1}{3}$	1	$\frac{3}{2}$	$\frac{5}{2}$	$\frac{16}{6}$	$\frac{18}{6}$

Pour  $u = 0,4$  on a  $c_1 = \frac{1}{3} \leq 0,4 < 1 = c_2$  donc on sélectionne le 2.

Pour  $u + 1 = 1,4$  on a  $c_2 = 1 \leq 1,4 < \frac{3}{2} = c_3$  donc on sélectionne le 3.

On s'arrête puisqu'on doit choisir 3 éléments et puisque le 4 est choisi d'office l'échantillon comporte le 2, 3 et 4.

3. On a :

$$\begin{aligned}
 \bar{x} &= \frac{1}{6} \sum_{k \in s} \frac{x_k}{\pi_k} \\
 &= \frac{1}{6} \left( \frac{x_2}{\pi_2} + \frac{x_3}{\pi_3} + \frac{x_4}{\pi_4} \right) \\
 &= \frac{1}{6} \left( \frac{4}{\frac{2}{3}} + \frac{3}{\frac{1}{2}} + 9 \right) \\
 &= \frac{1}{6} (6 + 6 + 9) = \frac{21}{6} = 3,5
 \end{aligned}$$

Comme  $\pi_k = \frac{x_k}{6} \forall k$  alors les  $\pi_k$  et les  $x_k$  sont parfaitement proportionnels, par construction on a une variance nulle, donc un estimateur est parfait pour la moyenne.

**Exercice 2:** Puisqu'il y 'a une relation à peu près proportionnelle entre le chiffre d'affaire et l'effectif salarié, le tirage à probabilité inégales proportionnellement au chiffres d'affaires est justifié.

On a pour tout  $k$  :  $\pi_k = n \frac{x_k}{t_x}$  avec  $n = 3$  et  $t_x = 60$

Puisque  $\pi_1 = 3 \times \frac{40}{60} = 2 > 1$  alors l'unité 1 est sélectionnée d'office et éliminée de la poplation, ce qui entraine

$$t_x = \sum_{k \in U \setminus \{1\}} x_k = 20$$

et

$$\pi_2 = \frac{(n-1)x_2}{t_x} = 2 \times \frac{10}{20} = 1$$

l'unité 2 est aussi sélectionnée d'office et éliminée de la population. Il reste à sélectionner une unité parmi les identifiants 3, 4, 5 et 6.

Comme

$$t_x = \sum_{k \in U \setminus \{1,2\}} x_k = 10$$

$$\pi_3 = \frac{8}{10} = 0,8 \quad \pi_4 = 0,1 \quad \pi_5 = 0,05 \quad \text{et} \quad \pi_6 = 0,05$$

Les probabilités d'inclusion cumulées valent (en notant  $c_k = \sum_{j=1}^k \pi_j$ )

$$c_3 = 0,8 \quad c_4 = 0,9 \quad c_5 = 0,95 \quad \text{et} \quad c_6 = 1$$

Comme  $c_3 = 0,8 \leq 0,83 < c_4 = 0,9 \Rightarrow$  l'unité 4 est sélectionnée. L'échantillon finalement sélectionné est  $s = \{1, 2, 4\}$

Si on modifie l'ordre du fichier les 2 plus grosses unités ( $x = 40$ ) et ( $x = 10$ ) sont toujours retenues d'office, quel que soit l'ordre initial. Avec le nombre tiré au hasard entre 0 et 1, tout dépend de la position de l'unité ( $x = 8$ ) lorsqu'on considère les 4 unités restantes ( $x = 0,5; 0,5; 1; 8$ ). Si l'unité ( $x = 8$ ) est dans la position 2, 3 ou 4 alors elle est toujours retenue (facile à vérifier). Si elle est en position 1, alors on peut retenir n'importe quelle valeur des 3 restantes.

L'ordre de fichier influe donc sur l'échantillon sélectionné.

**Exercice 3:** Soit une population de 5 unités. On veut sélectionner par un tirage systématique à probabilités inégales un échantillon de deux unités avec des probabilités d'inclusion proportionnelles aux valeurs  $x_i$  suivantes 1 ; 1 ; 6 ; 6 ; 6.

1. Avec  $n = 2$ , on a

$$t_x = \sum_{k=1}^5 x_k = 20, \quad \pi_k = n \frac{x_k}{t_x} \quad k = 1; \dots; 5$$

2. Le nombre de permutation est  $C_5^2 = \frac{5!}{2!3!} = \frac{5 \times 4}{2} = 10$

1	1	1	6	6	6
2	1	6	1	6	6
3	1	6	6	1	6
4	1	6	6	6	1
5	6	1	1	6	6
6	6	1	6	1	6
7	6	1	6	6	1
8	6	6	1	1	6
9	6	6	1	6	1
10	6	6	6	1	1

On peut remarquer que les permutations se décomposent en deux catégories

— les permutations où les 2 petites valeurs sont consécutives.




FIGURE 1 – Cas 1 : les deux petites valeurs sont adjacentes

— les permutations où les 2 petites valeurs sont séparées par une grande valeur.




FIGURE 2 – Cas 2 : les deux petites valeurs ne sont pas adjacentes

Donc pour examiner toutes les permutations, il suffit de se borner à examiner les 2 cas suivant

1	1	6	6	6
1	6	1	6	6

Les probabilités d'inclusion à l'ordre un valent respectivement pour les deux ordres

0,1	0,1	0,6	0,6	0,6
0,1	0,6	0,1	0,6	0,6

Dans les deux cas, il est impossible de choisir conjointement les 2 petites valeurs parce que le pas de tirage est 1, donc ceci est valide pour toutes les permutations possibles et donc leur probabilité d'inclusion d'ordre 2 est nulle. La conséquence principale est qu'il n'y a pas d'estimateur sans biais de la variance.

**Exercice 4:** Soit une population U composée de 6 unités. On connaît les valeurs prises par un caractère auxiliaire x sur toutes les unités de la population :

$$x_1 = 200, x_2 = 80, x_3 = 50, x_4 = 50, x_5 = 10, x_6 = 10.$$

1. On a pour tout  $k$  :  $\pi_k = n \frac{x_k}{t_x}$  avec  $n = 4$  et  $t_x = 400$

Puisque  $\pi_1 = 4 \times \frac{200}{400} = 2 > 1$  alors l'unité 1 est sélectionnée d'office et éliminée de la population, ce qui entraîne

$$t_x = \sum_{k \in U \setminus \{1\}} x_k = 200$$

et

$$\pi_2 = (n - 1) \times \frac{x_2}{t_x} = 3 \times \frac{80}{200} = 1,2 > 1$$

l'unité 2 est aussi sélectionnée d'office et éliminée de la population.

Il reste de sélectionner 2 unités parmi 4 :

on a

$$t_x = \sum_{k \in U \setminus \{1, 2\}} x_k = 120$$

ce qui entraîne

$$\pi_3 = \pi_4 = 2 \times \frac{50}{120} = \frac{5}{6} \quad \text{et} \quad \pi_5 = \pi_6 = 2 \times \frac{10}{120} = \frac{1}{6}$$

Les probabilités d'inclusion cumulées valent (en notant  $c_k = \sum_{j=3}^k \pi_j$ )

$$c_3 = \frac{5}{6} \quad c_4 = \frac{10}{6} \quad c_5 = \frac{11}{6} \quad \text{et} \quad c_6 = 2$$

d'où on sélectionne l'échantillon  $\{1; 2; 3; 4\}$




FIGURE 3 – Tirage systématique de 2 unités

2. Remarquons que pour tous  $k$  et  $l$ , si  $\pi_k = 1$  alors  $\pi_{kl} = \pi_l$ .

Soit  $u$  la valeur donnée par  $\mathcal{U}(0; 1)$

- si  $0 \leq u \leq \frac{4}{6}$  alors on tombe dans les intervalles n° 1 et 2, les deux unités sélectionnées sont  $\{3; 4\}$
- si  $\frac{4}{6} < u \leq \frac{5}{6}$  alors on tombe dans les intervalles n° 1 et 3, les deux unités sélectionnées sont  $\{3; 5\}$
- si  $\frac{5}{6} < u \leq 1$  alors on tombe dans les intervalles n° 2 et 4, les deux unités sélectionnées sont  $\{4; 6\}$

donc

$$\pi_{34} = \frac{4}{6} \quad \text{et} \quad \pi_{35} = \pi_{46} = \frac{1}{6}$$

Les autres combinaisons donnent bien  $\pi_{kl} = 0$ . En fin la matrice d'inclusion d'ordre deux est donnée par.

$$\begin{pmatrix} - & 1 & \frac{5}{6} & \frac{5}{6} & \frac{1}{6} & \frac{1}{6} \\ 1 & - & \frac{5}{6} & \frac{5}{6} & \frac{1}{6} & \frac{1}{6} \\ \frac{5}{6} & \frac{5}{6} & - & \frac{4}{6} & \frac{1}{6} & 0 \\ \frac{5}{6} & \frac{5}{6} & \frac{4}{6} & - & 0 & \frac{1}{6} \\ \frac{1}{6} & \frac{1}{6} & \frac{1}{6} & 0 & - & 0 \\ \frac{1}{6} & \frac{1}{6} & 0 & \frac{1}{6} & 0 & - \end{pmatrix}$$

3. d'après ce qui précède il y'a que 3 échantillons possible de taille 4 à savoir  $\{1; 2; 3; 4\}$ ,  $\{1; 2; 3; 5\}$  et  $\{1; 2; 4; 6\}$ . Le vrai total  $t_y = 200$

On rappelle que

$$\hat{t}_{y,\pi} = \sum_{k \in S} \frac{y_k}{\pi_k}.$$

$$\widehat{\mathbf{Var}}(\hat{t}_{y,\pi}) = -\frac{1}{2} \sum_{k \in s} \sum_{\substack{l \in s \\ l \neq k}} \left( \frac{y_k}{\pi_k} - \frac{y_l}{\pi_l} \right)^2 \frac{\pi_{kl} - \pi_k \pi_l}{\pi_{kl}}$$

On sait bien que  $\hat{t}_{y,\pi}$  est sans biais de  $t_y$ .

$s$	$\hat{t}_{y,\pi}$	$\widehat{\mathbf{Var}}(\hat{t}_{y,\pi})$	$p(s)$
$\{1; 2; 3; 4\}$	196	0,75	$\frac{4}{6}$
$\{1; 2; 3; 5\}$	226	-48	$\frac{1}{6}$
$\{1; 2; 4; 5\}$	190	0	$\frac{1}{6}$

conformément à la théorie  $\mathbb{E}[\hat{t}_{y,\pi}] = \sum p(s) \hat{t}_{y,\pi}(s) = 200$  et  $\mathbb{E}[\widehat{\mathbf{Var}}[\hat{t}_{y,\pi}]] < 0$  ce qui implique  $\mathbb{E}[\widehat{\mathbf{Var}}[\hat{t}_{y,\pi}]] \neq \mathbf{Var}[t_{y,\pi}] \geq 0$  car  $\pi_{kl} = 0$ .

M. BADAoui